

李婧漪

lijingyi030505@163.com
18108658857



教育背景

上海财经大学 (211 工程), 应用统计硕士 2025.9 - 2027.6

中南财经政法大学 (211 工程), 应用统计学本科, GPA:3.9/4.0(前 5%) 2021.9 - 2025.6

荣誉奖项: 校优秀学生、校级一等奖学金、全国大学生数学建模省奖

主修课程: 机器学习、时间序列分析、数据库管理、数据结构、模式识别与图像处理

技术栈

大模型应用: SFT、RLHF、Prompt Engineering、RAG、langgraph;

机器学习/深度学习: cv、Nlp、时间序列、Boost、MMOE 等常见推荐模型;

编程语言: PyTorch、SQL、Linux、matlab、R

实习经历

滴滴 | 国际化部门 | 风控算法实习生 2026.4 - 至今

项目一: 面向贷款风险的红蓝军对抗仿真 Agent 系统

(1) 项目难点: 针对滴滴海外贷款平台真实存在且业界暂无适配解决方案的 AIGC 欺诈风险, 构建多模态 Agent 红蓝对抗框架, 模拟黑产业链路与攻击策略演化过程, 实现潜在风险路径的自动发现与验证。

(2) 多模态 GUI Agent 框架设计: 基于 LangGraph 构建有状态 (Stateful) 的多步骤攻击编排 Agent, 采用 LLM Tool Calling 范式 (Gemini 2.5 Pro 决策 + 参数化 Tool 执行), 实现攻击流水线的自动规划与执行。Agent 读取 skill.md 作为攻击知识库, 通过 plan_pipeline 工具动态生成执行计划, 并结合 Action 执行过程中产生的环境状态、页面反馈及历史操作结果持续更新 State, 实现对后续步骤的自适应决策与路径调整, 支持从注册、实名认证、绑卡到交易、提现的全链路自动化攻击模拟。

(3) 蓝军级风控 Skills 构建: 基于真实黑产攻击链路, 对身份信息、证件图像、活体视频及行为序列等多模态数据进行统一建模, 构建可复用的攻击 Skill 库。结合 Seedance/klings/wan video 生成 Deepfake 活体视频、Veo 生成手持证件照, 并基于历史白样本行为轨迹与序列模型评分机制生成高仿真用户行为序列, 实现跨模态攻击素材的自动化组合与协同优化。

(4) Deepfake 假脸链路具体实现:

• 针对无评价标准下 Harness Engineering: 由于红蓝对抗场景缺乏客观评价基准 (无法用 FID/IS 等传统生成质量指标衡量攻击有效性), 设计基于业务闭环的 Harness 评价体系: 以攻击路径穿透率 (成功触达提现环节的比例) 为核心指标, 辅以风控模型拦截概率变化量 (攻击前后模型打分差值) 和活体检测通过率三个维度联合评估。构建参数化攻击用例库 (支持 action_type:count:intensity 三元组配置, 如 blink:2:0.8), 通过 YAML 热更新 Prompt 模板实现攻击策略的快速迭代与 A/B 对比, 无需重启 Agent 即可验证新攻击向量的有效性。

• 具体成果: 实现人体活体检测 60%+ 的成功率, 炫彩和灵动检验均有攻破成功例。

项目二: 墨西哥 BNPL 可信主体识别与风险分层模型

(1) 项目难点: 针对 BNPL 支付场景存在的问题, 第一是 BNPL 复支场景缺乏可信主体识别能力, 需要从设备指纹、手机号和收货地址三个维度建立可信关系网络; 第二是标签定义比较困难, 不同可信主体对应的风险聚集程度不同, 需要设计严格的 1V1 标签体系和差异化黑样本规则。

(2) 具体实现和解决思路: 采用 XGBoost 构建可信设备指纹模型、可信手机号模型及加白模型; 围绕可信主键开发交易活跃度、关联关系、历史风险行为及用户画像等特征, 并针对模型效果衰减问题进行专项分析, 发现风险表现期差异导致标签口径不一致, 进一步将标签统一为“支用前 22 天 + 支用后 22 天”的固定 44 天观察窗口, 保证训练集与评估集标签定义一致。在此基础上引入用户画像特征增强风险刻画能力, 模型整体 AUC 由 0.748 提升至 0.783, Top5% Lift 由 4.75 提升至 6.26, 显著提升高风险用户识别能力。

百融云创 | 金融与数据支持部门 | 大模型应用开发 2025.9 - 2026.1

项目三: 面向 ETF 投研场景的大模型对齐优化 (两阶段 SFT + RLHF)

(1) 项目难点: 以 Qwen3-4B 为 basemodel, 围绕 ETF 与金融投研场景构建垂域大模型后训练流水线, 旨在使模型具备 ETF 投资场景的专业能力, 同时不降低其金融泛化能力。

(2) 训练数据构建与评估 Pipeline: 基于大模型对原始数据进行多轮采样生成候选指令数据 (N=3 5); 随后设计统一评估 Prompt, 引入 LLM as a judge 对候选样本从相关性、正确性、完整性等维度进行打分; 在此基础上结合一致性投票机制 (Self-Consistency Voting), 仅保留评分稳定且多次生成结果一致 ($\geq 70\%$) 的样本; 针对边界样本引入规则过滤 (如长度异常、格式错误、字段缺失) 与人工抽样校验, 最终实现数据质量的自动化评估与噪声控制。

(3) 两阶段 SFT 对齐训练: 针对 ETF 场景在 lora 微调过程中模型在通用金融评测集 (FinEval) 上性能下降的问题, 设计两阶段 SFT 对齐方案:

• 针对专业领域能力增强的一阶段 sft: 基于大模型对 ETF 相关样本进行自动分类与质量打分, 构建约 200 条高质量 ETF 评测集, 综合三个评价方式来评估, 通过率 (人工抽样检验)、专业性评分 (3.5→4.0)、关键点覆盖率 (0.3→0.6) 均有显著提升。

• 针对灾难性遗忘的二阶段 sft: 针对 FinEval 评测集准确率下降 (68%→63%) 问题, 基于向量检索从金融语料中筛选约 2 万条高相似样本构建补充训练集, 进行第二阶段 SFT 微调, 使模型在 FinEval 上的准确率由恢复提升至 70%, 有效缓解领域过拟合, 实现垂域能力与通用能力的平衡。

(4) **DPO 偏好对齐优化**: SFT 后金融模型专业性评分显著提高, 但仍存在关键点覆盖不足、题目约束遵循不稳定等问题, 基于低覆盖率 ETF 数据和类别构造偏好对数据, 将参考答案作为 **chosen**、低覆盖模型输出作为 **rejected**, 开展 DPO 偏好优化训练, 使部分低覆盖率 (≤ 0.1) 类别问题有显著提升。

• **项目四：ETF 财富管理 Multi-Agent 系统**

(1) **项目难点**: 单 ETF 金融大模型虽具备专业问答能力, 但在复杂任务拆解、结构化数据交互、工具调用及报告生成等方面存在不足, 难以独立完成财富管理场景下的复杂任务。因此基于优化后的模型构建“主控智能体 + 专用智能体”架构, 实现意图理解、任务规划、RAG 检索、数据库查询、报告生成与可视化等能力。

(2) **具体实现**:

• **主控智能体与子智能体协同设计**: 系统采用“主控智能体 + 专用智能体”架构, 通过 TypedDict 定义统一 AgentState 作为全局共享状态协议, 结合条件路由函数实现多阶段任务编排, 并引入访问次数控制、异常快照回滚与中间状态增量更新机制, 避免智能体间循环调用、状态污染与执行失控, 意图解析准确率 $\geq 95\%$ 。

• **ReAct 推理与工具调用设计**: 在各专用智能体内部采用 ReAct (**Thought** $\rightarrow$ **Action** $\rightarrow$ **Observation**) 推理范式, 基于统一 BaseAgent 抽象封装大模型调用、工具解析、参数映射、批量工具执行与迭代控制逻辑; 注册知识库检索、数据库链接、可视化分析等相关工具, 实现模型的工具调用能力。

• **设计优化**: 针对用户自然语言表达与数据库结构化字段不一致, 导致 SQL 匹配失败的问题, 构建字段字典对齐与 RAG 检索模块, 实现语义级字段映射与关键词扩展, 有效降低数据查询与分析错误率, 将工具调用成功率由 65% 提升至 85%+; 同时针对**长上下文场景**, 设计轻量化长期记忆机制, 仅保留用户关注的股票、行业及风险偏好等关键信息, 以控制上下文规模并提升推理稳定性; 结合 Few-shot 示例与 JSON 结构化约束**优化 Prompt 设计**, 显著提升模型输出的可控性与格式一致性。

众安保险 | 数据科学部门 | 算法实习生

2025.4 - 2025.8

• **项目五：车辆保险自动化识别定损 workflow**

(1) **项目概述**: 针对人工识别车辆图片定级保险损伤的复杂流程, 构造自动化图像清理-车辆部位识别-保险级别定损流程。

(2) **具体实现**: 复现 **HVI (CVPR 2025,sota)** 图像增强模型, 应用于夜视车辆照片, 显著提升低光环境下图像亮度与细节, 根据百度 paddle 工具包指标, 使暗夜图转换为高达 **85%+**, 并部署上线相关功能; 利用开源车辆数据集与闭源公司内自标注数据集微调预训练 **Co-DETR (ICCV 2023,sota)** 模型, 实现保险杠、车门、翼子板等受损部位的实例分割与分类, 提高定损效率, mAP@0.5 高至 **80%+**。

学术成果

• Yang, Xinyi.¹; **Li, Jingyi.¹**; et al. Research on information leakage in time series prediction based on empirical mode decomposition. *Scientific Reports*. **2024**, 14, 28362. (JCR Q2, IF=4.6)

研究方向: 时间序列预测、EMD 信息泄露问题改进

主要解决问题: 基于 EMD 的时间序列预测中, 对全序列分解会泄漏测试集信息, 导致虚高精度。本文提出三种改进 EMD 分解策略——滑动窗口 (SW)、单训练多预测 (STMP)、多训练多预测 (MTMP), 从源头切断未来数据泄漏。