

半监督双重稳健Kink回归模型 处理效应检验方法研究 硕士学位论文开题报告

汇报人：李婧漪

上海财经大学统计与数据科学学院

2026年6月



上海财经大学
Shanghai University of Finance & Economics

- ① 选题背景与研究问题
- ② 模型与方法
- ③ 渐近性质与效率增益
- ④ 研究创新
- ⑤ 模拟实验
- ⑥ 实证应用与计划

1 选题背景与研究问题

2 模型与方法

3 渐近性质与效率增益

4 研究创新

5 模拟实验



6 实证应用与计划

选题背景

- 处理效应异质性检验是因果推断的核心问题
- 实际场景中，处理效应常随连续变量发生结构性改变
- Kink回归模型：在拐点 δ 处函数连续但斜率发生改变

$$Y_i = \alpha_0 + \alpha_1 X_i + \tau \cdot 1(X_i \geq \delta)(X_i - \delta) + \varepsilon_i$$

- $\tau \neq 0$ ：拐点处存在斜率变化（Kink效应）
- $\tau = 0$ ：无拐点效应，模型退化为普通线性回归



选题背景

- 标签稀缺问题：大数据时代普遍面临
 - 协变量和处理分配信息易大规模获取
 - 结果变量收集成本高昂
- 半监督数据结构：少量有标签数据 + 大量无标签数据

研究问题

本文聚焦三个核心问题：

- ① 如何构建半监督双重稳健检验统计量？
 - 倾向分数或结果模型至少一个正确时，保证Type I Error控制
- ② 如何通过非参数插补融入无标签数据？
 - 实现渐近方差缩减，提升检验功效
- ③ 如何设计高效的乘数自助法？
 - 避免大规模无标签数据下的计算瓶颈

- 1 选题背景与研究问题
- 2 模型与方法
- 3 渐近性质与效率增益
- 4 研究创新
- 5 模拟实验
- 6 实证应用与计划

模型设定

半监督Kink回归模型:

$$Y_i = \alpha_0 + \alpha_1 X_i + \tau A_i (X_i - \delta) 1(X_i \geq \delta) + \mu(W_i) + \varepsilon_i$$

- X : 连续运行变量 (如年龄、收入、生物标志物)
- δ : 未知拐点位置
- τ : 拐点处斜率变化量 (核心参数)
- A : 处理变量, $\mu(W)$: 协变量非线性效应

半监督数据结构:

- 标记数据集 $\mathcal{L} = \{(X_i, W_i, A_i, Y_i) : i = 1, \dots, n\}$
- 未标记数据集
 $\mathcal{U} = \{(X_j, W_j, A_j) : j = n + 1, \dots, n + N\}$, 缺失 Y
- $N \gg n$ (无标签样本远多于有标签样本)

研究目标: 检验 $H_0 : \tau = 0$ vs $H_1 : \tau \neq 0$

Score检验的动机

为什么采用Score检验而非Wald检验?

Wald检验需要联合估计 (τ, δ) , 但:

- 拐点 δ 是非规则参数, $\hat{\delta}$ 不满足 $\sqrt{n}$ 渐近理论
- 导致 $\hat{\tau}$ 的极限分布难以推导

Score检验的思路: 不直接估计 τ , 而是构造在 $\tau = 0$ 时期望为零的函数

直观例子: 考虑 $Y = \alpha + \tau X + \varepsilon$

- 若 $\tau = 0$, 则 $Y = \alpha + \varepsilon$, 此时 X 与残差 $Y - \alpha$ 无关
- 即 $E[X(Y - \alpha)] = 0$
- 构造 $S = \frac{1}{n} \sum_{i=1}^n X_i(Y_i - \hat{\alpha})$
- 若 $S \approx 0$, 说明 $\tau = 0$ 可能成立

Score函数的构建

Step 1: 基础矩条件

在 $H_0: \tau = 0$ 下, 定义 $h(X_i, W_i) = E(Y_i | X_i, W_i)$, 对于任意 $g(X_i, A_i)$:

$$E[g(X_i, A_i)\{Y_i - h(X_i, W_i)\}] = 0$$

选择 $g(X_i, A_i) = A_i(X_i - \delta)1(X_i \geq \delta)$, 得到:

$$E[A_i(X_i - \delta)1(X_i \geq \delta)\{Y_i - h(X_i, W_i)\}] = 0$$

问题: 要求 $h(X, W)$ 正确设定, 否则检验失效

引入倾向分数——双重稳健Score

定义倾向分数 $\pi(X_i, W_i) = P(A_i = 1|X_i, W_i)$

双重稳健Score函数：

$$\psi_1 = \underbrace{(X - \delta)1(X \geq \delta)}_{\text{拐点识别权重}} \cdot \underbrace{\{A - \hat{\pi}\}}_{\text{处理残差}} \cdot \underbrace{\{Y - \hat{h}\}}_{\text{结果残差}}$$

每一项的含义：

- $(X - \delta)1(X \geq \delta)$ ：只在拐点右侧起作用，放大拐点信号
- $\{A - \hat{\pi}\}$ ：消除选择偏差，处理非随机化问题
- $\{Y - \hat{h}\}$ ：控制协变量效应，提高估计精度

关键性质： $E[A - \pi(X, W)|X, W] = 0$ ，即 $A - \pi$ 与所有 (X, W) 函数正交

双重稳健性的数学推导

双重稳健性: $E[\psi] = 0$ 只需满足以下两条件之一:

$$\hat{h} = h \quad \text{或} \quad \hat{\pi} = \pi$$

情形一: 结果模型正确, 倾向分数模型错误

- $\hat{h} = h \Rightarrow E[Y - h|X, W, A] = 0$
- $E[\psi] = E[(A - \hat{\pi}) \cdot E[Y - h|X, W, A]] = 0$

情形二: 倾向分数模型正确, 结果模型错误

- 设误差 $r(X, W) = h - \hat{h}$, 则 $Y - \hat{h} = Y - h + r$
- $E[\psi] = E[(A - \pi)(Y - h)] + E[(A - \pi)r] = 0 + 0 = 0$

$\Rightarrow$ 倾向分数残差自动消除任何仅依赖于 (X, W) 的模型误差

半监督扩展：效率增强策略

核心问题：未标记数据缺失 Y ，如何利用？

效率增强的两个方面：

① 倾向分数的合并估计

- $\pi(X, W; \eta)$ 的估计只依赖 (A, X, W) ，不需要 Y
- 在合并数据集 $\mathcal{L} \cup \mathcal{U}$ （样本量 $M = n + N$ ）上估计 η
- 估计误差 $O_p(M^{-1/2})$ ，相对于 $\sqrt{n}$ 尺度渐近可忽略

② 结果模型参数的半监督估计

- ζ 必须依赖 Y ，但可利用无标签数据的协变量分布信息
- 通过半监督估计方程提高效率

估计方程的具体形式

倾向分数参数 η 的估计方程：

$$\Psi_2(\eta) = \frac{1}{M} \sum_{i=1}^M D_{\eta}(X_i, W_i) \{A_i - \pi(X_i, W_i; \eta)\} = 0$$

结果模型参数 ζ 的半监督估计方程：

$$\Psi_3(\zeta) = \frac{1}{n} \sum_{i=1}^n D_{\zeta}(X_i, W_i) \{Y_i - h(X_i, W_i; \zeta)\} + \frac{1}{N} \sum_{j=n+1}^{n+N} D_{\zeta}(X_j, W_j) \{\hat{m}_j - h_j\}$$

权重矩阵：

$$D_{\eta}(X_i, W_i) = [\pi(1 - \pi)]^{-1} \frac{\partial \pi}{\partial \eta}, \quad D_{\zeta}(X_i, W_i) = \frac{\partial h}{\partial \zeta}$$

$D_{\eta}(X_i, W_i)$ 包含逆方差加权，保证倾向分数估计的有效性

非参数插补：单指标NW核估计

目标：为无标签数据插补缺失的 Y

单指标的定义：

$$S_i = h(X_i, W_i; \hat{\zeta}_n)$$

- $h(X, W; \zeta)$ ：参数化结果模型
- $\hat{\zeta}_n$ ：参数估计值，由估计方程 $\Psi_3(\zeta) = 0$ 求得
- S_i ：将高维协变量 (X_i, W_i) 压缩为一维数值

单指标的意义：避免维数灾难

- 直接对高维 (X, W) 做核估计 $\rightarrow$ 收敛速度随维数指数下降
- 单指标降维后 $\rightarrow$ 核估计收敛速度不受协变量维数影响

Nadaraya-Watson核估计

NW核估计（在单指标 S 上做非参数回归）：

$$\hat{m}(X, W) = \frac{\sum_{i=1}^n Y_i K_{h_n}(S - S_i)}{\sum_{i=1}^n K_{h_n}(S - S_i)}$$

关键符号：

- $S = h(X, W; \hat{\zeta}_n)$ ：待预测点的单指标值
- $S_i = h(X_i, W_i; \hat{\zeta}_n)$ ：有标签样本的单指标值
- $K_{h_n}(u) = \frac{1}{h_n} K\left(\frac{u}{h_n}\right)$ ：标准化核函数

核函数示例：高斯核 $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$

带宽 h_n 的作用：控制平滑程度， h_n 越大越平滑

半监督Score的构造

有标签数据的Score:

$$\psi_i(\delta) = (X_i - \delta)1(X_i \geq \delta) \cdot \{A_i - \hat{\pi}(X_i, W_i)\} \cdot \{Y_i - \hat{h}(X_i, W_i)\}$$

无标签数据的Score (用核估计插补 Y) :

$$\bar{\psi}_j(\delta) = (X_j - \delta)1(X_j \geq \delta) \cdot \{A_j - \hat{\pi}(X_j, W_j)\} \cdot \{\hat{m}(X_j, W_j) - \hat{h}(X_j, W_j)\}$$

半监督Score (加权平均) :

$$\Psi_{SS}(\delta) = \lambda \cdot \frac{1}{n} \sum_{i=1}^n \psi_i(\delta) + (1 - \lambda) \cdot \frac{1}{N} \sum_{j=1}^N \bar{\psi}_j(\delta)$$

- $\lambda \in [0, 1]$: 权重参数, 平衡两类数据的贡献
- 当 $\lambda = 1$: 退化为传统监督方法

Sup-type检验统计量

检验统计量:

$$T_{n,SS} = \sup_{\delta \in \mathcal{D}} \left[\frac{\sqrt{n} \cdot \Psi_{SS}(\delta)}{\hat{\sigma}_{SS}(\delta)} \right]^2$$

- $\Psi_{SS}(\delta)$: 半监督Score函数
- $\hat{\sigma}_{SS}(\delta) = \sqrt{\widehat{\text{Var}}(\Psi_{SS}(\delta))}$: Score的标准差估计
- $\sup_{\delta \in \mathcal{D}}$: 在候选拐点集合上取上确界

搜索空间 $\mathcal{D}$ 的构造:

$$\mathcal{D} = \{\delta_{(k)} : k = \lceil M\theta \rceil, \dots, \lfloor M(1 - \theta) \rfloor\}$$

- $M = n + N$: 合并样本总量
- $\delta_{(k)}$: X 的第 k 个顺序统计量
- $\theta = 0.05$: 修剪常数, 去除两端各5%的极端值

为什么取上确界: 拐点 δ

乘数自助法

困难:

Sup-

type统计量的极限分布无解析形式, 传统Bootstrap计算量过大

乘数自助法: 不重抽样数据, 仅施加随机权重 $\xi_i \sim N(0, 1)$

$$\Psi_{SS}^*(\delta) = \frac{1}{n} \sum_{i=1}^n \xi_i \psi_i(\delta) + \frac{1}{N} \sum_{j=1}^N \xi_j \bar{\psi}_j(\delta)$$

扰动统计量:

$$T_{n,SS}^* = \sup_{\delta \in \mathcal{D}} \left[\frac{\sqrt{n} \cdot \Psi_{SS}^*(\delta)}{\hat{\sigma}_{SS}(\delta)} \right]^2$$

临界值: $c_{1-\alpha} = \inf\{c : P^*(T_{n,SS}^* \leq c) \geq 1 - \alpha\}$

决策: Reject H_0 if $T_{n,SS} > c_{1-\alpha}$

Algorithm 1: 乘数自助法计算p值

输入: $\mathcal{L}, \mathcal{U}, M = n + N, \mathcal{D}, (\hat{\eta}_M, \hat{\zeta}_M, \hat{m}), B$

Step 1: 计算观测统计量 $T_{n,SS}$

Step 2: 在网格 $\mathcal{D}$ 上计算调整影响函数 $\hat{\psi}_{SS}^*(O_k; \delta)$

Step 3: 对于 $b = 1, \dots, B$:

(a) 抽取 $\xi^{(b)} = (\xi_1^{(b)}, \dots, \xi_M^{(b)})^\top \sim N(0, I_M)$

(b) 计算:

$$T_{n,SS}^{*(b)} = \sup_{\delta \in \mathcal{D}} \frac{n}{\hat{\sigma}_{SS}^2(\delta)} \left[\frac{\lambda}{n} \sum_{i=1}^n \xi_i^{(b)} \hat{\psi}_{SS}^*(Z_i; \delta) + \frac{1-\lambda}{N} \sum_{j=n+1}^{n+N} \xi_j^{(b)} \hat{\psi}_{SS}^*(O_j; \delta) \right]^2$$

Step 4: $p\text{-value} = \frac{1}{B} \sum_{b=1}^B \mathbf{1}(T_{n,SS}^{*(b)} > T_{n,SS})$

调整影响函数的定义

为什么需要调整影响函数：

- nuisance参数 ($\hat{\eta}_M, \hat{\zeta}_M$) 的估计误差会影响Score的分布
- 调整影响函数将估计误差的影响“投影”出去

有标签数据的调整影响函数：

$$\hat{\psi}_{SS}^*(Z_i; \delta) = \psi_i(\delta) - \hat{C}_\eta \cdot \hat{D}_\eta(X_i, W_i) \{A_i - \hat{\pi}(X_i, W_i)\}$$

无标签数据的调整影响函数：

$$\hat{\psi}_{SS}^*(O_j; \delta) = \bar{\psi}_j(\delta) - \hat{C}_\zeta \cdot \hat{D}_\zeta(X_j, W_j) \{\hat{m}(X_j, W_j) - \hat{h}(X_j, W_j)\}$$

关键符号：

- $Z_i = (X_i, W_i, A_i, Y_i)$ ：有标签数据的完整观测
- $O_j = (X_j, W_j, A_j)$ ：无标签数据（缺失 Y ）
- $\hat{C}_\eta, \hat{C}_\zeta$ ：调整系数，由估计方程的导数计算得到

- 1 选题背景与研究问题
- 2 模型与方法
- 3 渐近性质与效率增益
- 4 研究创新
- 5 模拟实验
- 6 实证应用与计划

正则条件

- (C1) 估计方程存在唯一解 η_0, ζ_0 (可识别性)
- (C2) $\hat{\eta}_M, \hat{\zeta}_M$ 渐近线性, 协方差矩阵有限非奇异
- (C3) $\text{Var}(Y|h(X, W; \zeta_0))$ 有界, 单指标 $S = h(X, W; \zeta_0)$ 有连续有界密度
- (C4) $0 < P(X \geq \delta) < 1$ 对任意 $\delta \in \mathcal{D}$ (拐点两侧有足够样本)
- (C5) $n/N \rightarrow \rho \in [0, \infty)$ (兼容无标签数据主导情形)
- (C6) 带宽条件: $h_n \rightarrow 0, nh_n \rightarrow \infty, nh_n^4 \rightarrow 0$
 - $h_n \rightarrow 0$: 偏差消失; $nh_n \rightarrow \infty$: 方差可控; $nh_n^4 \rightarrow 0$: 欠平滑
- (C7) $\{\psi_{SS}^*(\cdot; \delta) : \delta \in \mathcal{D}\}$ 为P-Donsker类

调整影响函数 ψ_{SS}^* : 将辅助参数估计误差从Score中投影出去

$$\sqrt{n}\Psi_{SS}(\delta) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi_{SS}^*(Z_i; \delta) + o_p(1)$$

定理1：极限分布与双重稳健性

定理1：在 $H_0 : \tau = 0$ 下，若 π 或 h 至少一个正确设定，则

$$T_{n,SS} \xrightarrow{d} \sup_{\delta \in \mathcal{D}} G_{SS}^2(\delta)$$

其中 $\{G_{SS}(\delta) : \delta \in \mathcal{D}\}$ 为均值为零的高斯过程。

意义：

- 确认双重稳健性——任一模型正确即可保证Type I Error控制

-

极限分布非标准（高斯过程上确界），需Bootstrap获得临界值

定理2：效率增益

定理2：设 $\Sigma_1(\delta)$ 为监督Score方差， $\Sigma_{ss}(\delta)$ 为半监督Score方差，则

$$\Sigma_{ss}(\delta) = \Sigma_1(\delta) - \Delta(\delta), \quad \Delta(\delta) \geq 0$$

且在一般条件下 $\Delta(\delta) > 0$ 。

直觉理解：

- 无标签数据提供协变量分布 $P(X, W)$ 的精确信息
- 通过核估计插补 $E[Y|h(X, W)]$ ，利用条件期望结构
- 方差缩减量 $\Delta(\delta)$ 正是协变量分布信息对Score方差的“贡献”

⇒ 融入无标签数据必然降低方差

定理3：功效提升

定理3：在局部替代 $H_{1n} : \tau = n^{-1/2}c_0$ 下，

$$T_{n,SS} \xrightarrow{d} \sup_{\delta \in \mathcal{D}} [G_{SS}(\delta) + \mu_{SS}(\delta)]^2$$

非中心参数：

$$\mu_{SS}(\delta) = \frac{c_0 \cdot E[\pi(1 - \pi)(X - \delta)(X - \delta_0)1(X \geq \max\{\delta, \delta_0\})]}{\sigma_{SS}(\delta)}$$

关键发现：

- 分子（信号强度）与全监督方法完全相同
- 分母 $\sigma_{SS}(\delta) < \sigma_1(\delta)$ （由定理2）
- 因此 $\mu_{SS}(\delta) > \mu_1(\delta)$ ，非中心参数被放大

⇒ 方差缩减转化为功效提升

定理4: Bootstrap一致性

定理4: 在 H_0 和 (C1) – (C7) 下,

$$\sup_{x \in \mathbb{R}} |P^*(T_{n,SS}^* \leq x) - P(T_{n,SS} \leq x)| \xrightarrow{P} 0$$

意义: Bootstrap分布一致逼近真实分布, Bootstrap分位数可作为渐近正
理论结果总结:

定理	核心结论	理论意义
定理1	极限分布成立	Type I Error可控
定理2	$\Sigma_{SS} < \Sigma_1$	效率增益
定理3	$\mu_{SS} > \mu_1$	功效提升
定理4	Bootstrap一致性	可获得正确临界值

- 1 选题背景与研究问题
- 2 模型与方法
- 3 渐近性质与效率增益
- 4 研究创新**
- 5 模拟实验
- 6 实证应用与计划

研究创新

① 构建了半监督双重稳健Kink检验的统一理论框架

- 首次在Kink结构下，将双重稳健性、半监督学习与Sup-type检验统一
- 建立非规则参数下的非标准极限分布理论
- 保证模型错设下的双重稳健渐近正态性
- 证明Sup-type非光滑泛函的极限过程表示

② 严格证明半监督效率增益的理论结果

- 给出 $\Delta(\delta)$ 的具体表达式
- 揭示效率增益来源于无标签数据中协变量分布的额外信息

- 1 选题背景与研究问题
- 2 模型与方法
- 3 渐近性质与效率增益
- 4 研究创新
- 5 模拟实验
- 6 实证应用与计划

模拟实验设计

数据生成过程:

$$X \sim \text{Uniform}(-1, 1) \text{ 或 } N(0, 1), \quad W \sim N(0, I_2)$$

$$Y = 1 + 0.5X + \tau A(X - \delta)1(X \geq \delta) + 0.3W_1 + 0.2W_2 + \varepsilon$$

方法对比:

- Labeled-only: 仅用标记数据
- Semi-supervised: 标记+未标记数据
- Oracle full-data: 假设所有Y已知 (上界)

参数设置: $n \in \{200, 400\}$, $N/n = 5$, $\tau \in \{0, 0.3, 0.5, 0.8\}$, $\alpha = 0.05$

Type I Error控制

Table 1: $X \sim \text{Uniform}(-1, 1)$ 时的Type I Error ($\alpha = 0.05$)

设置	Labeled-only	Semi-supervised	Oracle
$\sigma = 0.5, n = 200$	0.038	0.040	0.062
$\sigma = 0.5, n = 400$	0.072	0.060	0.056
$\sigma = 1.0, n = 200$	0.070	0.046	0.064
$\sigma = 1.0, n = 400$	0.056	0.050	0.048

Table 2: $X \sim N(0, 1)$ 时的Type I Error ($\alpha = 0.05$)

设置	Labeled-only	Semi-supervised	Oracle
$\sigma = 0.5, n = 200$	0.052	0.058	0.044
$\sigma = 0.5, n = 400$	0.046	0.070	0.042
$\sigma = 1.0, n = 200$	0.050	0.056	0.054
$\sigma = 1.0, n = 400$	0.042	0.056	0.054

检验功效结果

- 随着 τ 从0.3增加到0.8，拒绝率明显上升
- 样本量 $n = 200 \rightarrow 400$ 后，功效整体提高
- Oracle full-data具有最高功效（使用全部响应变量信息）
- Semi-supervised方法相对于Labeled-only保持接近或略有改进




Figure 1: *

检验功效对比

模拟实验结论

主要发现：

- 原假设下检验水平总体可控
- 备择假设下拒绝率随kink强度和样本量增加而上升
- 无标签样本中的协变量信息能够在一定程度上改善检验表现

- 1 选题背景与研究问题
- 2 模型与方法
- 3 渐近性质与效率增益
- 4 研究创新
- 5 模拟实验
- 6 实证应用与计划

实证应用计划

ACTG175数据集（HIV治疗临床试验）：

- 2139名HIV患者，四种抗逆转录病毒治疗方案
- 运行变量：基线CD4细胞计数
- 考察治疗效应是否存在Kink型结构性变化

PBC数据集（原发性胆汁性胆管炎）：

- 424名PBC患者，D-青霉胺治疗
- 运行变量：血清胆红素
- 检验治疗对生存的影响是否存在拐点

时间安排

时间	主要任务
2026.6 – 7	文献深度研读与定理证明推导
2026.8 – 9	完善模拟实验、扩展DGP设置
2026.10 – 11	实证应用与论文初稿
2026.12 – 2027.5	修改完善与答辩准备

Thanks!

请各位老师批评指正