

# 李婧漪

lijingyi030505@163.com  
18108658857



## 教育背景

上海财经大学 (211 工程), 应用统计硕士 2025.9 - 2027.6

中南财经政法大学 (211 工程), 应用统计学本科, GPA:3.9/4.0(前 5%) 2021.9 - 2025.6

荣誉奖项：校优秀学生、校级一等奖学金、全国大学生数学建模省奖

主修课程：机器学习、时间序列分析、数据库管理、数据结构、模式识别与图像处理

## 技术栈

大模型应用：SFT、RLHF、Prompt Engineering、RAG、langgraph;

机器学习/深度学习：cv、Nlp、时间序列、Boost、MMOE 等常见推荐模型;

编程语言：PyTorch、SQL、Linux、matlab、R

## 实习经历

滴滴 | 国际化部门 | 风控算法实习生 2026.4 - 至今

### 项目一：面向贷款风险的红蓝对抗仿真 Agent 系统

(1) 项目背景：针对滴滴海外贷款平台真实存在且业界暂无成熟解决方案的 AIGC 欺诈风险，设计多模态红蓝对抗仿真框架，模拟黑产攻击链路及策略演化过程，实现潜在风险路径的自动发现、验证与风控能力评估。

(2) Stateful 多模态 GUI Agent 设计：基于 MAI-UI 二次封装 Stateful GUI Agent，在原生 GUI Navigation 能力基础上扩展业务流程状态 (State) 管理、攻击 Skill 编排及流程恢复机制，采用 Gemini 2.5 Pro 作为 Planner，通过 Tool Calling 驱动 GUI 操作，形成“页面感知 (VLM) — 状态更新 (State) — 任务规划 (Planner) — Tool 执行 — 结果评估”的闭环执行链路。Agent 持续维护页面状态、业务阶段、历史 Action 及攻击上下文，实现注册、实名认证、证件上传、活体检测、绑卡、交易、提现等贷款全流程自动化攻击仿真，并支持动态路径调整及异常恢复。

(3) 多模态攻击 Skill 库与子 Agent 构建：基于真实黑产攻击链路，对身份信息、证件图像、活体视频及行为序列进行统一建模，设计可复用攻击 Skill 库及多模态子 Agent。针对活体检测环节，构建 Live Detection 对抗子 Agent，融合 Seedance/Kling/Wan Video 生成活体视频素材及 Veo 生成手持证件场景图像，基于 VLM 对视频帧级视觉特征、动作完整性及检测反馈进行分析，自动生成姿态调整、光照扰动、素材优化等策略，实现“素材生成—检测反馈—策略调整”的迭代优化闭环。行为序列采用“真实轨迹 + Rule Mining + Few-shot + LLM + 序列模型评分”的生成框架，在业务规则约束下生成高仿真攻击样本，实现身份素材、活体素材与行为轨迹的跨模态协同仿真。

(4) 自动评测与对抗优化闭环：设计 Agent 自动评测框架，构建动作级 (GUI Action)、流程级 (Business Workflow) 及风控级 (Risk Signal) 三级评测体系。其中针对活体检测流程，增加图像质量、视频一致性、人脸状态及检测反馈等多维评估指标，结合失败原因分析驱动 Skill 参数调整；动作级验证点击、输入及页面跳转执行正确性；流程级验证实名认证、证件上传、活体检测等关键节点完成情况；风控级综合设备风险、历史子 Agent 执行结果及攻击链路状态，实现失败节点定位、风险原因分析及策略迭代优化。

(5) 项目成果：完成贷款业务关键链路 (实名认证、证件上传、活体检测等) 的自动化攻击仿真，相关子 Agent 达到稳定执行成功率；完成 100+ 高仿真行为序列生成与自动评估，成功发现并验证多处真实风控漏洞，为风控策略优化及对抗测试提供自动化能力支撑。

### 项目二：墨西哥 BNPL 可信主体识别与风险分层模型

(1) 项目难点：针对 BNPL 支付场景存在的问题，第一是 BNPL 复支场景缺乏可信主体识别能力，需要从设备指纹、手机号和收货地址三个维度建立可信关系网络；第二是标签定义比较困难，不同可信主体对应的风险聚集程度不同，需要设计严格的 1V1 标签体系和差异化黑样本规则。

(2) 具体实现和解决思路：采用 XGBoost 构建可信设备指纹模型、可信手机号模型及加白模型；围绕可信主键开发交易活跃度、关联关系、历史风险行为及用户画像等特征，并针对模型效果衰减问题进行专项分析，发现风险表现期差异导致标签口径不一致，进一步将标签统一为“支用前 22 天 + 支用后 22 天”的固定 44 天观察窗口，保证训练集与评估集标签定义一致。在此基础上引入用户画像特征增强风险刻画能力，模型整体 AUC 由 0.748 提升至 0.783，Top5% Lift 由 4.75 提升至 6.26，显著提升高风险用户识别能力。

百融云创 | 金融与数据支持部门 | 大模型应用开发 2025.9 - 2026.1

### 项目三：面向 ETF 投研场景的大模型对齐优化 (两阶段 SFT + RLHF)

(1) 项目难点：以 Qwe3-4B 为 basemodel，围绕 ETF 与金融投研场景构建垂域大模型后训练流水线，旨在使模型具备 ETF 投资场景的专业能力，同时不降低其金融泛化能力。

(2) 训练数据构建与评估 Pipeline：基于大模型对原始数据进行多轮采样生成候选指令数据 (N=3 5)；随后设计统一评估 Prompt，引入 LLM as a judge 对候选样本从相关性、正确性、完整性等维度进行打分；在此基础上结合一致性投票机制 (Self-Consistency Voting)，仅保留评分稳定且多次生成结果一致 ( $\geq 70\%$ ) 的样本；针对边界样本引入规则过滤 (如长度异常、格式错误、字段缺失) 与人工抽样校验，最终实现数据质量的自动化评估与噪声控制。

(3) 两阶段 SFT 对齐训练：针对 ETF 场景在 lora 微调过程中模型在通用金融评测集 (FinEval) 上性能下降的问题，设计两阶段 SFT 对齐方案：

• 针对专业领域能力增强的一阶段 sft：基于大模型对 ETF 相关样本进行自动分类与质量打分，构建约 200 条高质量 ETF 评测集，综合三个评价方式来评估，通过率 (人工抽样检验)、专业性评分 (3.5→4.0)、关键点覆盖率 (0.3→0.6) 均有显著

提升。

• **针对灾难性遗忘的二阶段 sft**：针对 FinEval 测评集准确率下降 (68%→63%) 问题，基于向量检索从金融语料中筛选约 2 万条高相似样本构建补充训练集，进行第二阶段 SFT 微调，使模型在 FinEval 上的准确率由恢复提升至 70%，有效缓解领域过拟合，实现垂域能力与通用能力的平衡。

(4) **DPO 偏好对齐优化**：SFT 后金融模型专业性评分显著提高，但仍存在关键点覆盖不足、题目约束遵循不稳定等问题，基于低覆盖率 ETF 数据和类别构造偏好对数据，将参考答案作为 chosen、低覆盖模型输出作为 rejected，开展 DPO 偏好优化训练，使部分低覆盖率 ( $\leq 0.1$ ) 类别问题有显著提升。

• **项目四：ETF 财富管理 Multi-Agent 系统**

(1) **项目难点**：单 ETF 金融大模型虽具备专业问答能力，但在复杂任务拆解、结构化数据交互、工具调用及报告生成等方面存在不足，难以独立完成财富管理场景下的复杂任务。因此基于优化后的模型构建“主控智能体 + 专用智能体”架构，实现意图理解、任务规划、RAG 检索、数据库查询、报告生成与可视化等能力。

(2) **具体实现**：

• **主控智能体与子智能体协同设计**：系统采用“主控智能体 + 专用智能体”架构，通过 TypedDict 定义统一 AgentState 作为全局共享状态协议，结合条件路由函数实现多阶段任务编排，并引入访问次数控制、异常快照回滚与中间状态增量更新机制，避免智能体间循环调用、状态污染与执行失控，意图解析准确率  $\geq 95\%$ 。

• **ReAct 推理与工具调用设计**：在各专用智能体内部采用 ReAct (Thought → Action → Observation) 推理范式，基于统一 BaseAgent 抽象封装大模型调用、工具解析、参数映射、批量工具执行与迭代控制逻辑；注册知识库检索、数据库链接、可视化分析等相关工具，实现模型的工具调用能力。

• **设计优化**：针对用户自然语言表达与数据库结构化字段不一致，导致 SQL 匹配失败的问题，构建字段字典对齐与 RAG 检索模块，实现语义级字段映射与关键词扩展，有效降低数据查询与分析错误率，将工具调用成功率由 65% 提升至 85%+；同时针对长上下文场景，设计轻量化长期记忆机制，仅保留用户关注的股票、行业及风险偏好等关键信息，以控制上下文规模并提升推理稳定性；结合 Few-shot 示例与 JSON 结构化约束优化 Prompt 设计，显著提升模型输出的可控性与格式一致性。

众安保险 | 数据科学部门 | 算法实习生

2025.4 - 2025.8

• **项目五：车辆保险自动化识别定损 workflow**

(1) **项目概述**：针对人工识别车辆图片定级保险损伤的复杂流程，构造自动化图像处理-车辆部位识别-保险级别定损流程。

(2) **具体实现**：复现 HVI (CVPR 2025,sota) 图像增强模型，应用于夜视车辆照片，显著提升低光环境下图像亮度与细节，根据百度 paddle 工具包指标，使暗夜图转换为高达 85%+，并部署上线相关功能；利用开源车辆数据集与闭源公司内自标注数据集微调预训练 Co-DETR (ICCV 2023,sota) 模型，实现保险杠、车门、翼子板等受损部位的实例分割与分类，提高定损效率，mAP@0.5 高至 80%+。

学术成果

• Yang, Xinyi.<sup>1</sup>; Li, Jingyi.<sup>1</sup>; et al. Research on information leakage in time series prediction based on empirical mode decomposition. *Scientific Reports*. 2024, 14, 28362. (JCR Q2, IF=4.6)

研究方向：时间序列预测、EMD 信息泄露问题改进

主要解决问题：基于 EMD 的时间序列预测中，对全序列分解会泄漏测试集信息，导致虚高精度。本文提出三种改进 EMD 分解策略——滑动窗口 (SW)、单训练多预测 (STMP)、多训练多预测 (MTMP)，从源头切断未来数据泄漏。