

具有处理效应的折点回归模型中的半监督双稳健检验

刘飞翔¹ 和刘旭^{1*}

上海财经大学

2026年5月24日

摘要

关键词：

* 通讯作者。刘旭系上海财经大学统计与数据科学学院教授，邮编200433，中国上海。电子邮箱：
liu.xu@mail.shufe.edu.cn 。

1 引言

2 模型

设 Y 为感兴趣的响应变量, X 为单变量阈值变量, $A \in \{0, 1\}$ 的二元处理指标, W 为可能影响结果的 p 维附加协变量向量。

我们考虑一种半监督设置, 其中观测数据由一个标注数据集 L 和一个无标签数据集 U 。有标签数据集包含 n 个独立观测值 $L = \{Z_i = (X_i, W^T, A_i, Y_i)^T : i = 1, \dots, n\}$ 。无标签数据集包含 N 个独立观测值 $U = \{(X_j, W^T, A_j)^T : j = n+1, \dots, n+N\}$, 其中响应变量 Y 缺失。我们假设 L 和 U 中的数据均来自相同的底层分布。在典型的半监督场景中, 无标签样本的规模远大于有标签样本的规模, 即 $N \gg n$ 。

我们考虑一种回归模型, 该模型允许在因变量 X 上的处理效应中存在一个未知的拐点。具体而言, 该模型定义为

$$Y = \alpha_0 + \alpha_1 X + \tau A(X - \delta)\mathbf{1}(X \geq \delta) + \mu(W) + \varepsilon, \quad (1)$$

其中 α_0 是截距, α_1 是未接受干预时 X 的基线斜率, τ 代表受试组特有的拐点效应幅度, δ 是干预效应可能发生变化的未知阈值 (拐点), $\mu(W)$ 是描述协变量 W 效应的未知平滑函数。误差项 ε 被假设满足标准的外生性条件 $E[\varepsilon | A, X, W] = 0$ 。

项 $\tau A(X - \delta)\mathbf{1}(X \geq \delta)$ 将异质性处理效应明确建模为连续变量 X 的函数。它确保折点效应仅适用于受处理组 ($A = 1$), 并且只有当 X 超过未知阈值 δ 时才会生效。在此公式中, 该模型可以捕捉以下情况: 在阈值以下, 处理效应微乎其微或不存在, 但在阈值以上则线性增加 (或减少), 这反映了处理响应中的结构变化。

我们主要关注的是检验干预是否表现出异质效应, 其特征是在某个未知连续变量值处发生结构性变化 (拐点)。

从形式上讲，这相当于检验“处理效应在 X 的所有取值下均一致”这一原假设，与“在某个未知点存在拐点”这一备择假设进行对立检验：

$$H_0 : \tau = 0 \quad \text{对} \quad H_a : \tau \neq 0. \quad (2)$$

在零假设下，模型简化为一种标准线性回归，其中处理效应是同质的且不随 X 变化；而在备择假设下，存在一个个体子群体，当 X 超过阈值 δ 时，该子群体的处理效应会发生系统性变化。

3 方法

3.1 半监督双稳健评分检验

在完全监督设置中，当所有响应均被观测时，检验零假设 $H_0 : \tau = 0$ 可通过双稳健评分函数来表述。遵循标准的半参数理论，针对第 i 个个体的候选阈值 δ 处所评估的评分的核心部分由下式给出

$$\psi_1(Z_i; \delta, \eta, \zeta) = \frac{1}{n} (X_i - \delta) \mathbf{1}(X_i \geq \delta) \left(A_i - \pi(X_i, W_i; \eta) \right) - \frac{1}{n} (Y_i - h(X_i, W_i; \zeta)), \quad (3)$$

其中 $\pi(X_i, W_i; \eta) = P(A_i = 1 | X_i, W_i)$ 是倾向得分模型，而 $h(X_i, W_i; \zeta) = E[Y_i | X_i, W_i]$ 是 H_0 下的基线结果回归模型。式(3)中的构造保证了双重稳健性：只要倾向得分模型或基线结果模型中任一者被正确指定，则在 H_0 下，估计方程的期望为零。

然而，仅依赖规模为 n 的小型标记数据集 L 会产生方差较大的检验统计量，导致检测结构性变化的功效不足。为了充分利用规模为 N 的海量未标记数据集 U ，我们提出了一种效率提升策略，该策略在两个相互关联的方面进行操作：倾向得分的汇总估计和未观测得分的非参数插补。

首先，我们注意到倾向得分模型 $\pi(X, W; \eta)$ 的估计仅依赖于处理分配 A 和协变量 (X, W) ，从而无需使用缺失的结局变量 Y 。因此，我们可以通过最大化二项式对数似然

对整个规模为 $M = n + N$ 的合并数据集 LuU 进行二项式对数似然最大化。令 $\hat{\eta}_M$ 表示该合并估计量。由于 $M \gg n$ ， $\hat{\eta}_M$ 的估计误差与通常的 $n^{-1/2}$ 收敛速率相比，渐近上可忽略不计，从而有效消除了

。反之，基准结果参数 ζ （其严格要求 Y ）则仅使用标注数据 L 进行估计，从而得到估计量 $\hat{\zeta}_n$ 。

基于该优化的倾向得分估计量，我们将进一步探讨未观测的未标注数据的评分函数的组成部分。对于集合 U 中的第 j 个未标注观测值，响应变量 Y_j 缺失。一种统计上合理的做法是将 (3) 式中不可观测的 Y_j 替换为其条件期望 $m(X, W; \zeta) = E[Y | h(X, W; \zeta)]$ 。这种替换得出了未标注数据的条件期望评分：

$$\bar{\psi}_1(X_j, W_j, A_j; \delta) = \frac{1}{n} (X_j - \delta) \mathbf{1}(X_j \geq \delta) - \frac{1}{n} A_j - \pi(X_j, W_j; \hat{\eta}_M) - \frac{1}{n} m(X_j, W_j; \zeta) - h(X_j, W_j; \zeta). \quad (4)$$

为了在规避维度诅咒的同时对 $m(X, W, A)$ 进行非参数估计，我们采用了一个单指标的纳达拉亚-沃森 (NW) 核估计量。对于单一索引，一个自然且有效的选择是源自基线模型的线性预测测量 $S_i = h(X_i, W_i; \hat{\zeta}_n)$ 。利用标注数据集 L，在给定索引 s 和处理组 a 下的 NW 估计量定义为

$$\hat{m}(X, W; \zeta) = \frac{\sum_{i=1}^n Y_i K_h(h(X, W; \zeta) - h(X_i, W_i; \zeta))}{\sum_{i=1}^n K_{hn}(h(X, W; \zeta) - h(X_i, W_i; \zeta))}, \quad (5)$$

其中 $K_{hn}(\cdot) = h_n^{-1} K(\cdot/h_n)$ 是一个带宽为 $h_{(n)}$ 的对称核密度函数。

将 (5) 代入 (6) 可得插补后的分数观测值，即对于每个未标注的观测值， $\hat{\psi}_1(X_j, W_j, A_j; \delta)$

$$\hat{\psi}_1(X_j, W_j, A_j; \delta) = \frac{1}{n} (X_j - \delta) \mathbf{1}(X_j \geq \delta) - \frac{1}{n} A_j - \pi(X_j, W_j; \hat{\eta}_M) - \frac{1}{n} \hat{m}(X_j, W_j; \hat{\zeta}_M) - h(X_j, W_j; \hat{\zeta}_M), \quad (6)$$

其中 $\hat{\zeta}_M$ 和 $\hat{\eta}_M$ 分别表示在零模型下获得的干扰参数的估计量。

具体而言，这些参数满足以下估计方程：

$$\begin{aligned}\Psi_2(\eta) &= \frac{1}{n} \sum_{i=1}^n D_\eta(X_i, W_i) (A_i - \pi(X_i, W_i; \eta)) = 0, \\ \Psi_3(\zeta) &= \frac{1}{n} \sum_{i=1}^n D_\zeta(X_i, W_i) (Y_i - h(X_i, W_i; \zeta)) \\ &\quad + \frac{1}{N} \sum_{i=n+1}^N D_\zeta(X_i, W_i) (\hat{m}(X_i, W_i; \zeta) - h(X_i, W_i; \zeta)) = 0,\end{aligned}$$

其中 $D_\eta(X_i, W_i) = [\pi(X_i, W_i; \eta)\{1 - \pi(X_i, W_i; \eta)\}]^{-1} \partial \pi(X_i, W_i; \eta) / \partial \eta$ 以及 $D_\zeta(X_i, W_i) = \partial h(X_i, W_i; \zeta) / \partial \zeta$ 分别是结果模型和倾向得分模型的基于得分的权重矩阵。值得注意的是， D_η 融合了逻辑回归经典高效得分中的逆方差加权特性，确保在正确规格下对 π 进行高效估计。

通过策略性地综合 L 中观测到的评分与 U 中插补的评分，我们将半监督双稳健评分函数定义为加权平均值：

$$\Psi_{SS}(\delta) = \frac{\lambda}{n} \sum_{i=1}^n \psi(Z_i; \delta, \hat{\eta}_M, \hat{\zeta}_n) + \frac{1-\lambda}{N} \sum_{j=n+1}^{n+N} \psi_1(X_j, W_j, A_j; \delta), \quad (7)$$

其中 $\lambda \in [0, 1]$ 是一个权重参数，用于控制两个数据集的相对贡献（例如，将 λ 设为 n/M 意味着赋予每个观测值相等的权重）。

为了检验 H_0 ，我们遍历一系列候选阈值，并构造一个使反对原假设的证据达到最大值的上界型检验统计量：

$$T_{n,SS} = \sup_{\delta \in D} \frac{\sqrt{n}}{\hat{\sigma}_{SS}(\delta)} \Psi_{SS}(\delta), \quad (8)$$

其中 $\hat{\sigma}_{SS}^2(\delta)$ 是 $\sqrt{n} \Psi_{SS}(\delta)$ 的渐近方差的一致估计量。在

备择假设 $H_a: \tau \neq 0$ 下，结构变化最大的位置可通过标准化平方评分最大值进行一致估计，记为 $\hat{\delta} = \arg \max_{\delta \in D} \{n \Psi_{SS}^2(\delta) / \hat{\sigma}_{SS}^2(\delta)\}$ 。

在实际应用中，搜索区间 D 被限制在 X 的支撑集内部，以确保任何候选阈值两侧都有足够的样本量。利用庞大的合并数据集，我们将 D 构造为

$\{X_k\}_{k=1}^M$

的截尾

$$D = \{\delta_{(k)} : k = \lceil M\theta \rceil, \dots, \lfloor M(1 - \theta) \rfloor\},$$

集:

其中 $\delta_{(k)}$ 是合并阈值变量的第 k 个顺序统计量, θ 是一个较小的截断常数 (例如, $\theta = 0.05$)。

这种构造方法避免了边界效应, 并确保了稳健的非参数插补。

3.2 渐近性质

为了建立半监督检验统计量 $T_{n,SS}$ 的渐近性质, 我们必须考虑干扰参数引入的变异性。在我们的设置中, 这些包括参数估计量 $\hat{\eta}_M$ (基于 $M = n + N$ 个样本拟合) 和 $\hat{\zeta}_n$ (基于 n 个样本拟合), 以及非参数单指数 NW 估计量 $\hat{m}(\cdot)$ 。

由于 $\hat{\eta}_M$ 是利用庞大的合并数据集估计的, 其收敛速率为 $O_p(M^{-1/2})$ 。当按 $\sqrt{n}$ 进行缩放时, 其一阶估计误差变为 $O_p(\sqrt{n/M})$, 若 $N \gg \sqrt{n}$, 该误差将渐近趋于零; 若 $n/N \rightarrow \rho > 0$, 则该误差贡献微乎其微。因此, 变异的主要来源来自 ζ 的估计和 m 的非参数插补。我们令 $\psi_{S^*}^*(Z_i; \delta)$ 表示半监督调整影响函数, 该函数从评分函数中投影出 $(\hat{\eta}_M, \hat{\zeta}_n, \hat{m})$ 的主导阶估计误差。

为确保一致的渐近有效性, 我们施加以下正则性条件:

(C1) 干扰参数 ζ 和 η 的估计方程在其各自参数空间的紧子集上具有唯一解 (ζ_0, η_0) 。

(C2) 参数估计量在渐近意义上呈线性, 且其渐近方差矩阵为有限且正定。

(C3) 条件方差 $\text{Var}(Y | X, W, A)$ 具有一致有界性。单指标

$S = h(X, W; \zeta_0)$ 具有连续且有界的密度。

(C4) 对于 D 内部的任意候选阈值 δ , 概率 $P(X \geq \delta)$ 远离 0 和 1 且严格受限。

(C5) 当 $\min(n, N) \rightarrow \infty$ 时, 样本量比 $n/N \rightarrow \rho \in [0, \infty)$ 。

(C6) 核函数 $K(\cdot)$ 是一个有界、对称的概率密度。带宽宽度 h_n 满足 $h_n \rightarrow 0$ 、 $nh_n \rightarrow \infty$ 以及 $nh_n^4 \rightarrow 0$ ，以防止渐近偏差主导非参数估计。

(C7) 函数类 $\{\psi_{S^*}^*(\cdot; \delta) : \delta \in D\}$ 是 P-Donsker 的。

备注。 条件 (C1)–(C4) 和 (C7) 是半参数双稳健推断和经验过程的标准要求。条件 (C5) 和 (C6) 专属于我们的半监督框架。条件 (C5) 涵盖了各种缺失数据情景，包括未标注数据占主导地位的情况 ($\rho = 0$)。条件 (C6) 为 Nadaraya-Watson 估计量提供了标准带宽要求，以确保均匀收敛和避免过度平滑。

定理 1 在假设 (C1)–(C7) 下，假设至少一个干扰模型 $\pi(X, W; \eta)$ 或 $h(X, W; \zeta)$ 被正确指定。那么，在零假设 $H_0 : \tau = 0$ 下，半监督检验统计量满足

$$T_{n,SS} \xrightarrow{d} \sup_{\delta \in D} G_{SS}^2(\delta),$$

其中 $\{G_{SS}(\delta) : \delta \in D\}$ 是一个均值为零的高斯过程，其协方差函数为

$$\text{Cov}(G_{SS}(\delta_1), G_{SS}(\delta_2)) = \sqrt{\frac{\mathbb{E}[\psi_{S^*}^*(Z; \delta_1) \psi_{SS}^*(Z; \delta_2)]}{\mathbb{E}[\psi^{*2}(Z_{SS}; \delta)] \mathbb{E}[\psi^{*2}(Z_{SS}; \delta)]^{1/2}}}$$

定理 1 验证了所提出的检验在半监督设置下保持了双重稳健性，并能有效控制 I 类错误。其极限分布是高斯过程的上界，其协方差结构考虑了 U 上的非参数插值。

纳入无标签数据集的基本动机在于通过降低评分函数的方差来提高检验

。设 $\Sigma_1(\delta) = \lim_{n \rightarrow \infty} \text{Var}(\sqrt{n} \Psi_1(\delta))$

表示全监督评分的渐近方差，而 $\Sigma_{SS}(\delta) = \lim_{n \rightarrow \infty} \text{Var}(\sqrt{n} \Psi_{SS}(\delta))$

表示半监督评分量的渐近方差。

$$\frac{1}{n} \sum_{i=1}^n \psi_1^*(Z_i; \delta)$$

定理 2 在与定理 1 相同的条件下, 并采用最优加权参数 $\lambda = \rho/(1 + \rho)$ (其中若 $\rho = 0$, 则 $\lambda \rightarrow 0$) , 半监督评分函数的渐近方差满足

$$\Sigma_{SS}(\delta) = \Sigma_1(\delta) - \Delta(\delta),$$

其中 $\Delta(\delta) \geq 0$ 。此外, 只要 $\text{Var } E[\psi_1(Z; \delta) | X, W, A] > 0$ 。

定理 2 严格证明了效率的提升。通过使用条件期望 $m(X, W, A)$ 对未标注数据的评分进行非参数插补, 我们提取了嵌入在 (X, W, A) 边缘分布中的宝贵结构信息。这实际上将原始评分投影到一个变异性更低的子空间上, 使得 $\Sigma_{SS}(\delta)$ 严格小于 $\Sigma_1(\delta)$ 。

为了从理论上量化这种方差降低如何转化为检验力的提升, 我们研究了检验在局部备择假设下的行为。

定理 3 在定理 1 的条件下, 考虑一组连续的局部备择假设

$$H_{1n} : \tau = n^{-1/2} c_0, \quad c_0 \neq 0.$$

则当 $\min(n, N) \rightarrow \infty$ 时, 检验统计量 $T_{n,SS}$ 的分布收敛于

$$T_{n,SS} \xrightarrow{d} \sup_{\delta \in D} [G_{SS}(\delta) + \mu_{SS}(\delta)]^2,$$

其中 $G_{SS}(\delta)$ 是定理 1 中定义的高斯过程, 而非中心性参数 (漂移函数) $\mu_{SS}(\delta)$ 由下式给出

$$\mu_{SS}(\delta) = \frac{c_0 \int \pi(X, W) \{1 - \pi(X, W)\} (X - \delta)(X - \delta_0) \mathbf{1}(X \geq \max\{\delta, \delta_0\})}{\sigma_{SS}(\delta)},$$

其中 δ_0 表示真实的折点位置, 且 $\sigma_{SS}(\delta) = \sqrt{\Sigma_{SS}(\delta)}$ 。

定理 3 深刻揭示了所提方法的运作机制。漂移函数 $\mu_{SS}(\delta)$ 的分子与完全监督测试中的分子保持一致,

这代表了结构变化的真实信号。然而，由于定理2保证了 $\sigma_{SS}(\delta) < \sigma_1(\delta)$ ，因此非中心参数 $\mu_{SS}(\delta)$ 相较于其完全监督学习对应量被严格高估。漂移函数中这种确定性的向上偏移显著提高了上界统计量超过临界值的概率，从而在理论上确保了针对局部备择假设时具有显著更高的渐近功效。

3.3 临界值的计算

定理1中建立的半监督检验统计量 $T_{n,SS}$ 的渐近零分布是一个复高斯过程的上界。由于其协方差结构与未知的数据生成机制密切相关，因此无法通过解析推导求得临界值。此外，传统的非参数引导法——该方法要求在迭代过程中反复重新估计汇总倾向得分 $\hat{\eta}_M$ 、基线模型 $\hat{\zeta}_n$ ，并重新计算单指标NW核估计量 $\hat{m}(\cdot)$ ——当无标签样本量 N 巨大时，其计算成本极高。

为克服这一计算瓶颈，我们提出了一种高效的乘子自举（扰动重采样）方法来近似极限零分布。设 $\psi_{SS}^*(O_k; \delta)$ 表示第 k 个观测值（ $k = 1, \dots, M$ ）的调整影响函数 ψ_{SS}^* 的经验估计 $\hat{\psi}_{SS}^*$ ，其中 O_k 代表有标签或无标签受试者的可用数据。该经验调整影响函数考虑了干扰参数的一阶估计误差（显式公式参见附录）。

方差估计量 $\sigma^2_{SS}(\delta)$ 是通过使用这些

调整后的影响函数的样本方差计算得出。

我们生成一组独立的标准正态随机变量序列 $\xi = (\xi_1, \dots, \xi_M)^\top$ ，该序列与观测数据相互独立。扰动后的半监督检验统计量构造如下：

$$T_{n,SS}^* = \sup_{\delta \in D} \frac{n}{\sigma_{SS}^2(\delta)} \left(\frac{\lambda}{n} \sum_{i=1}^n \xi_i \psi_{SS}^*(Z_i; \delta) + \frac{1-\lambda}{N} \sum_{j=n+1}^{n+N} \xi_j \psi_{SS}^*(X_j, W_j, A_j; \delta) \right)^2. \quad (9)$$

通过反复生成 $\{\xi_k\}_{k=1}^M$ 的独立子集 $k=1, \dots, K$ ，我们可以模拟大量受扰的检验统计量。 $T_{n,SS}^*$ 的经验分布在零假设下，为 $T_{n,SS}$ 的极限分布提供了一个一致的近似。这一

该重采样算法由以下定理正式保证。

定理 4 在零假设及条件 (C1)–(C7) 下，以观测到的合并数据 $L \cup U$ 为条件，我们有

$$\sup_{x \in \mathbb{R}} P^* (T_{n,SS}^* \leq x) - P (T_{n,SS} \leq x) \xrightarrow{p} 0,$$

其中 P^* 表示由乘数自助法扰动 ξ 诱导的概率测度，而 $T_{n,SS}^*$ 是式(9)中定义的受扰检验统计量

。

定理 4 保证 $T_{n,SS}^*$ 的 α -分位数上限 (记为 C_α) 可作为渐近精确的临界值。若 $T_{n,SS} > C_\alpha$ ，则 α 水平检验将拒绝原假设 H_0 。

为便于本方法的实际应用，搜索空间 D 可以通过基于合并

阈值变量 $\{X_k\}^{(M)}$ 的经验分位数 $\frac{k}{M}$ 计算 p 值的完整流程总结如下

总结于算法 1 中。

4 模拟研究

5 案例研究

6 结论 备注 附录：定理证明

算法 1 半监督双稳健检验的乘数自举法

要求：标注数据 L 、无标签数据 U 、合并样本量 $M = n + N$ 、预定义的阈值搜索空间 D 拟合的干扰量估计量 $(\hat{\eta}_M, \hat{\zeta}_n, \hat{m})$ 以及一个大整数 B 。

确保：估计的 p 值。

1: 使用式(8)计算观测检验统计量 $T_{n,SS}$ 。

2: 针对网格上的所有 $k = 1, \dots, M$ ，计算经验调整影响函数 $\psi_{SS}^*(O_k; \delta)$ 上求值。

3: **对于** $b = 1, 2, \dots, B$ **执行**

4: **步骤 1.** 从标准多

正态分布 $N(0, I_M)$ 中抽取扰动向量 $\xi^{(b)}(O) = (\xi^{(b)}(O)(1), \dots, \xi^{(b)}(O)(M))^\top$ 。

5: **步骤 2.** 计算受扰的半监督检验统计量：

$$T_{n,SS}^{*(b)} = \sup_{\delta \in D} \frac{n}{\varphi_{SS}(\delta)} \left(\frac{\lambda}{n} \sum_{i=1}^n \xi_i^{(b)\top} \hat{\psi}_{SS}(Z_i; \delta) + \frac{1-\lambda}{N} \sum_{j=n+1}^{n+N} \xi_j^{(b)\top} \hat{\psi}_{SS}(X_j, W_j, A_j; \delta) \right)^2.$$

6: **结束 for**

7: **步骤 3.** 根据引导样本统计量的经验分布计算 p 值：

$$p\text{值} = \frac{1}{B} \sum_{b=1}^B \mathbf{1}_{T_{n,SS}^{*(b)} > T_{n,SS}}.$$

参考文献